

Εργασία Μηχανικής Μάθησης: Ανάλυση και Ταξινόμηση Δεδομένων

Περιγραφή Εργασίας

Σε αυτή την εργασία θα εφαρμόσετε διάφορες τεχνικές μηχανικής μάθησης για την ανάλυση και ταξινόμηση δεδομένων. Καλείστε να εργαστείτε σε ομάδες, να επιλέξετε κατάλληλα σύνολα δεδομένων και να εφαρμόσετε μεθόδους που καλύπτουν όλο το φάσμα της ύλης του μαθήματος.

Διαδικασία Σχηματισμού Ομάδων και Επιλογή Tasks

1. Σχηματίστε ομάδες των 2-3 ατόμων.
2. Κάθε ομάδα θα πρέπει να δηλωθεί την **27/03/2025** μέσω του εργαλείου «Εργασίες» του eclass. Συγκεκριμένα, κάθε ομάδα θα πρέπει να ανεβάσει ένα αρχείο PDF στο οποίο θα αναφέρονται:
 - Τα ονόματα των μελών της ομάδας
 - Μία σύντομη περιγραφή του task ταξινόμησης που θα υλοποιηθεί
 - Τα σύνολα δεδομένων που θα χρησιμοποιηθούν (τόσα σύνολα δεδομένων όσα και τα μέλη της ομάδας)
3. **Σημαντική διευκρίνιση:** Κάθε μέλος της ομάδας θα είναι υπεύθυνο για την επιλογή και ανάλυση ενός διαφορετικού συνόλου δεδομένων, αλλά η ομάδα θα πρέπει να ασχοληθεί με το ίδιο task ταξινόμησης σε όλα τα σύνολα δεδομένων. Για παράδειγμα, εάν το task είναι "ανίχνευση απάτης", κάθε μέλος θα χρησιμοποιήσει ένα διαφορετικό σύνολο δεδομένων για ανίχνευση απάτης.

Προτεινόμενα Σύνολα Δεδομένων και Tasks

Παρακάτω παρατίθενται μερικές προτάσεις για tasks ταξινόμησης και αντίστοιχα σύνολα δεδομένων. Οι φοιτητές είναι ελεύθεροι να επιλέξουν κάποιο από αυτά τα tasks ή να προτείνουν δικό τους, και μετά να επιλέξουν διαφορετικά σύνολα δεδομένων για το ίδιο task. Όλα τα σύνολα δεδομένων πρέπει να πληρούν τις προδιαγραφές της ενότητας Α παρακάτω.

1. **Task: Ιατρική Διάγνωση**
 - Διάγνωση Διαβήτη (Pima Indians Diabetes Dataset)
 - Πρόβλεψη Καρδιακών Παθήσεων (Heart Disease UCI)
 - Ανίχνευση Καρκίνου του Μαστού (Breast Cancer Wisconsin Dataset)
 - Διάγνωση Πνευμονικών Παθήσεων (Chest X-Ray Images Dataset)
2. **Task: Πρόβλεψη Περιβαλλοντικών Κινδύνων**
 - Πρόβλεψη Δασικών Πυρκαγιών (Forest Fires Dataset)
 - Πρόβλεψη Πλημμυρών (Global Flood Database)
 - Πρόβλεψη Ξηρασίας (US Drought Monitor Dataset)
 - Ταξινόμηση Ποιότητας Αέρα (Air Quality Index Datasets)
3. **Task: Ανίχνευση Οικονομικής Απάτης**
 - Ανίχνευση Απάτης Πιστωτικών Καρτών (Credit Card Fraud Detection)
 - Ανίχνευση Απάτης σε Ασφαλιστικές Απαιτήσεις (Insurance Claim Fraud Detection)
 - Ανίχνευση Απάτης σε Τραπεζικές Συναλλαγές (Bank Transaction Fraud Detection)
 - Ανίχνευση Απάτης στο Ηλεκτρονικό Εμπόριο (E-commerce Fraud Detection)
4. **Task: Ανάλυση Συναισθήματος**
 - Ανάλυση Συναισθήματος σε Κριτικές Ταινιών (IMDB Movie Reviews)
 - Ανάλυση Συναισθήματος σε Κριτικές Προϊόντων (Amazon Product Reviews)
 - Ανάλυση Συναισθήματος σε Tweets (Twitter Sentiment Analysis Dataset)
 - Ανάλυση Συναισθήματος σε Σχόλια Ειδήσεων (News Comments Sentiment Dataset)

5. **Task: Αναγνώριση Αντικειμένων σε Εικόνες**
 - Αναγνώριση Ζώων (Animals-10 Dataset)
 - Αναγνώριση Οχημάτων (Stanford Cars Dataset)
 - Αναγνώριση Τροφίμων (Food-101 Dataset)
 - Αναγνώριση Φυτών (PlantVillage Dataset)
6. **Task: Αναγνώριση Ηχητικών Προτύπων**
 - Αναγνώριση Μουσικών Ειδών (GTZAN Dataset)
 - Αναγνώριση Φωνής (Speech Commands Dataset)
 - Αναγνώριση Περιβαλλοντικών Ήχων (ESC-50 Dataset)
 - Αναγνώριση Συναισθήματος από Ομιλία (RAVDESS Dataset)

Για κάθε task, οι φοιτητές θα πρέπει να επιλέξουν διαφορετικά σύνολα δεδομένων (όσα και τα μέλη της ομάδας) και να εφαρμόσουν τους ίδιους αλγορίθμους και μεθοδολογίες σε όλα τα σύνολα δεδομένων. Αυτό θα επιτρέψει τη συγκριτική ανάλυση της απόδοσης των αλγορίθμων σε διαφορετικά σύνολα δεδομένων που αφορούν το ίδιο πρόβλημα ταξινόμησης.

Απαιτήσεις Εργασίας

A. Επιλογή Συνόλων Δεδομένων

1. Κάθε μέλος της ομάδας θα επιλέξει ένα διαφορετικό σύνολο δεδομένων ταξινόμησης.
2. Τα σύνολα δεδομένων μπορούν να προέρχονται από αποθετήρια όπως UCI ML Repository, Kaggle, ή άλλες πηγές ανοιχτών δεδομένων.
3. Κάθε σύνολο δεδομένων πρέπει να:
 - Περιέχει τουλάχιστον 1000 παραδείγματα
 - Είναι κατάλληλο για προβλήματα ταξινόμησης
 - Το μέγεθος του dataset και οι απαιτήσεις επεξεργασίας των δεδομένων θα πρέπει να είναι συμβατά με τους περιορισμούς υπολογιστικών πόρων του Google Colab, ώστε να είναι εφικτή η εκπαίδευση των νευρωνικών δικτύων

B. Προεπεξεργασία και Εξερεύνηση Δεδομένων

Για κάθε σύνολο δεδομένων, πραγματοποιήστε λεπτομερή ανάλυση και προεπεξεργασία ακολουθώντας τα παρακάτω βήματα:

1. Εξερευνητική Ανάλυση Δεδομένων (EDA)

α. Στατιστική περιγραφή των δεδομένων:

- Υπολογισμός βασικών στατιστικών μέτρων (μέση τιμή, διάμεσος, τυπική απόκλιση, min, max, εκατοστημόρια) για κάθε αριθμητικό χαρακτηριστικό
- Ανάλυση της κατανομής των κλάσεων-στόχων (class distribution) και εντοπισμός τυχόν ανισορροπιών (class imbalance)
- Έλεγχος για ακραίες τιμές (outliers) και επεξήγηση της προσέγγισης διαχείρισής τους

2. Προεπεξεργασία Δεδομένων

α. Χειρισμός ακραίων τιμών:

- Ποσοτική ανάλυση των ελλειπουσών τιμών ανά χαρακτηριστικό και οπτικοποίησή τους (π.χ., με heatmap)

- Διερεύνηση των προτύπων ελλειπουσών τιμών (Missing Completely at Random, Missing at Random, Missing Not at Random)
- Εφαρμογή και αιτιολόγηση της επιλεγμένης μεθόδου χειρισμού ελλειπουσών τιμών:
 - Διαγραφή παρατηρήσεων ή χαρακτηριστικών
 - Απλή αντικατάσταση (μέση τιμή, διάμεσος, επικρατούσα τιμή)
 - Προηγμένες μέθοδοι αντικατάστασης (KNN imputation, matrix factorization)
- Αξιολόγηση της επίδρασης της επιλεγμένης μεθόδου στην κατανομή των δεδομένων

β. Κανονικοποίηση/Τυποποίηση χαρακτηριστικών:

- Επιλογή και αιτιολόγηση της κατάλληλης μεθόδου κλιμάκωσης για κάθε χαρακτηριστικό:
 - Min-Max scaling (κανονικοποίηση στο διάστημα $[0,1]$ ή $[-1,1]$)
 - Standard scaling (μετατροπή σε Z-scores)
 - Robust scaling (με βάση τα τεταρτημόρια, για ανθεκτικότητα σε ακραίες τιμές)
 - Log transformation ή άλλοι μη γραμμικοί μετασχηματισμοί
- Σύγκριση των κατανομών των χαρακτηριστικών πριν και μετά την κλιμάκωση
- Ανάλυση της επίδρασης της κλιμάκωσης στη διακριτική ικανότητα των χαρακτηριστικών

γ. Επιλογή και μετασχηματισμός χαρακτηριστικών:

- Αφαίρεση χαρακτηριστικών με χαμηλή διακύμανση
- Δημιουργία νέων χαρακτηριστικών (feature engineering) με βάση την κατανόηση του προβλήματος
- Εφαρμογή πολυωνυμικών χαρακτηριστικών ή άλλων μετασχηματισμών όπου είναι απαραίτητο
- Αιτιολόγηση των επιλεγμένων μετασχηματισμών και του αντίκτυπού τους στο πρόβλημα

δ. Διαχωρισμός σε σύνολα εκπαίδευσης, επικύρωσης και ελέγχου

Γ. Μείωση Διαστάσεων

Εφαρμόστε τουλάχιστον δύο από τις ακόλουθες τεχνικές μείωσης διαστάσεων:

1. Principal Component Analysis (PCA)
2. Linear Discriminant Analysis (LDA)
3. t-SNE (t-Distributed Stochastic Neighbor Embedding)
4. Αυτοκωδικοποιητές (Autoencoders)

Συγκρίνετε τα αποτελέσματα και αναλύστε πώς επηρεάζεται η αποδοτικότητα των μοντέλων.

Δ. Κλασικοί Αλγόριθμοι Ταξινόμησης

Εφαρμόστε τους ακόλουθους αλγορίθμους ταξινόμησης:

1. Λογιστική Παλινδρόμηση (Logistic Regression)
2. Support Vector Machines
3. k-Κοντινότεροι Γείτονες (k-NN)
4. Naive Bayes

Για κάθε αλγόριθμο:

- Βελτιστοποιήστε τις υπερπαραμέτρους μέσω τεχνικών cross-validation
- Αξιολογήστε την απόδοση με κατάλληλες μετρικές (accuracy, precision, recall, F1-score, ROC-AUC)
- Οπτικοποιήστε τα όρια απόφασης (όπου είναι εφικτό)

Ε. Βαθιά Νευρωνικά Δίκτυα

Σχεδιάστε και εκπαιδεύστε τουλάχιστον δύο αρχιτεκτονικές βαθιών νευρωνικών δικτύων:

1. Ένα απλό πολυεπίπεδο νευρωνικό δίκτυο (MLP)
2. Μία από τις ακόλουθες αρχιτεκτονικές (ανάλογα με τη φύση των δεδομένων):
 - Συνελικτικό Νευρωνικό Δίκτυο (CNN) για δεδομένα εικόνας
 - Αναδρομικό Νευρωνικό Δίκτυο (RNN) / LSTM / GRU για χρονοσειρές ή κειμενικά δεδομένα
 - Μοντέλο μετασχηματιστή (Transformer) για κειμενικά δεδομένα

Για κάθε δίκτυο:

- Δικαιολογήστε την επιλογή της αρχιτεκτονικής
- Πειραματιστείτε με διαφορετικές υπερπαραμέτρους (αριθμός επιπέδων, νευρώνων, ρυθμός μάθησης, συναρτήσεις ενεργοποίησης)
- Εφαρμόστε τεχνικές κανονικοποίησης (regularization) για αποφυγή της υπερπροσαρμογής
- Οπτικοποιήστε τη διαδικασία εκπαίδευσης (καμπύλες μάθησης)

ΣΤ. Συγκριτική Ανάλυση

1. Συγκρίνετε τις επιδόσεις όλων των αλγορίθμων σε κάθε σύνολο δεδομένων.
2. Αναλύστε τα πλεονεκτήματα και τα μειονεκτήματα της κάθε προσέγγισης.
3. Συζητήστε τη σχέση μεταξύ της πολυπλοκότητας του μοντέλου και της απόδοσης.
4. Προτείνετε βελτιώσεις ή εναλλακτικές προσεγγίσεις.

Παραδοτέα

1. **Αναφορά** (PDF, μέγιστο 15 σελίδες) που περιλαμβάνει:
 - Εισαγωγή και περιγραφή του προβλήματος
 - Περιγραφή των συνόλων δεδομένων
 - Μεθοδολογία και προσέγγιση
 - Πειραματικά αποτελέσματα και ανάλυση
 - Συμπεράσματα και προτάσεις για μελλοντική έρευνα
 - Βιβλιογραφικές αναφορές
 - Χρησιμοποιήστε το template του NeurIPS
<https://www.overleaf.com/latex/templates/neurips-2024/tpsbbbrdqcmsh>
2. **Κώδικας** (Jupyter Notebooks):
 - Καλά τεκμηριωμένος με σχόλια
 - Αναπαραγώγιμος (περιλαμβάνει οδηγίες εγκατάστασης απαιτούμενων βιβλιοθηκών)
 - Οργανωμένος σε ξεχωριστά αρχεία για κάθε σύνολο δεδομένων και μέθοδο
3. **Παρουσίαση** (10-15 λεπτά):
 - Σύντομη παρουσίαση των συνόλων δεδομένων
 - Κύρια ευρήματα και αποτελέσματα
 - Συγκριτική ανάλυση των μεθόδων

- Επίδειξη των πιο ενδιαφερόντων αποτελεσμάτων

Αξιολόγηση

Η βαθμολόγηση θα βασιστεί στα ακόλουθα κριτήρια:

- Ορθότητα της εφαρμογής των αλγορίθμων και ποιότητα κώδικα (40%)
- Βάθος ανάλυσης και ερμηνείας των αποτελεσμάτων (30%)
- Ποιότητα της αναφοράς (10%)
- Παρουσίαση (20%)

Χρονοδιάγραμμα

- **[27/03/2025]**: Προθεσμία δήλωσης ομάδων
- **[03/04/2025]**: Προθεσμία υποβολής προτάσεων για τα σύνολα δεδομένων
- **[08/05/2025]**: Ενδιάμεση αναφορά (2-3 σελίδες) για την πρόοδο
- **[28/05/2025]**: Τελική προθεσμία υποβολής όλων των παραδοτέων
- **[Ιούνιος 2025]**: Παρουσιάσεις/ Προφορική εξέταση

Σημειώσεις

- Ενθαρρύνεται η χρήση των βιβλιοθηκών scikit-learn, PyTorch για την υλοποίηση των αλγορίθμων.
- Η λογοκλοπή ή αντιγραφή κώδικα χωρίς κατάλληλη αναφορά θα οδηγήσει σε μηδενισμό της εργασίας.
- Ενθαρρύνεται η δημιουργικότητα και η εφαρμογή πρόσθετων μεθόδων πέραν των απαιτούμενων.